

④ Parte 1

Repaso

1 - Un modelo estadístico es una representación simplificada de la relación entre variables. Que intenta predecir/describir sus comportamientos entre sus elementos están:

variable dependiente: Y que depende de X

variable independiente: X influye en Y ,
pueden ser varias (X_1, X_2, \dots, X_p)

Parámetros:

Coefficientes β_0 intercepto y

pendientes β_1, \dots que miden el cambio en Y por X .

Supuestos: Describan como se distribuyen los errores o datos.

Ej.

$$RLS: Y = \beta_0 + \beta_1 X + E$$

$$LLM: Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + E$$

Donde E es la variabilidad no explicada

2 - es una cantidad que depende del azar, cambia de valor cada que se repite el experimento.

3 - es una formula que se utiliza datos muestrales para aproximar un parametro poblacional.

$$(X^T X)^{-1} X^T Y = \hat{\beta} \quad \text{no sesgado}$$
$$E[\hat{\beta}] = \beta$$

4- es una función o transformación que preserva/mantiene las operaciones de suma vectorial y multiplicación por escalar. Se cumple:

$$① T(u+v) = T(u) + T(v)$$

$$② T(cu) = cT(u)$$

Preserva la estructura lineal!

8- Es una función de los datos y del parámetro - tiene una distribución conocida y que está libre de parámetros desconocidos.

6- Se encuentra una cantidad pivotal con distribución conocida. Se fija una probabilidad central, se despeja el parámetro lo cual da el intervalo de confianza.

7- Es esperanza, el valor promedio esperado.

$$E[X] = \sum x_i P(x_i)$$

$$- E[aX+b] = aE[X] + b$$

$$- E[X+Y] = E[X] + E[Y]$$

$$- E\left(\sum a_i X_i\right) = \sum a_i E(X_i)$$

Variancia: dispersión respecto a la media.

$$- \text{Var}(AZ) = A \text{Var}(Z) A'$$

$$- \text{Var}(A+B) = \text{Var}(A) + \text{Var}(B) + 2\text{Cov}(A,B)$$

$$- \text{Var}(aX) = a^2 \text{Var}(X)$$

$$- \text{Var}(aX \pm bY) = a^2 \text{Var}(X) \pm 2ab \text{Cov}(X,Y) + b^2 \text{Var}(Y)$$

$$\pm 2ab \text{Cov}(X,Y)$$

$$- \text{Var}\left(\sum a_i X_i\right) = \sum a_i^2 \text{Var}(X_i) + \sum a_i a_j \text{Cov}(X_i, X_j)$$

8 - es la probabilidad de obtener un resultado al menos tan extremo como el observado por los datos.

$p \leq \alpha$ rechaza H_0

$p > \alpha$ no se rechaza H_0

En RLS

$H_0: \beta = 0$ no hay relación entre x y y

Se hace estadístico de prueba

Sirve para ver que variables contribuyen al modelo. La prueba F en ANOVA evalúa si al menos un predictor es útil.

el p-value mide la fuerza de la evidencia contra H_0

$$H_0: \beta_1 = \beta_2 = \dots = 0$$

9 - establece que la prueba basada en la razón de verosimilitud es la más poderosa entre las que tienen el mismo nivel de significancia.

$$\Lambda = \frac{L(\theta_0)}{L(\theta_1)} \Rightarrow \text{Rechaza } H_0 \text{ si}$$

si los datos son mucho más probables bajo H_1 que bajo H_0 se rechaza H_0

$$H_0: \theta = \theta_0$$

$$H_1: \theta = \theta_1$$

Se usa para construcción de intervalos de confianza

10- Si $z \sim N(0,1) \Rightarrow z^2 \sim \chi_1^2$

de hecho la t-student = Normal

chi cuadrada.

Las variables aleatorias i.i.d con $N(0,1)$ son variables

$$z_i \sim \chi_k^2$$

que siguen distribución
grados (libre)

chi cuadrado con k

11- La χ^2 no centrada aparece cuando la media del vector normal no es cero.

$$z \sim N(\mu, I) \Rightarrow z^T z \sim \chi^2(\lambda)$$

parametro

de no

centralidad $\lambda = \|\mu\|^2$

12- Un estimador no sesgado -

es el que su valor esperado coincide con

el parametro verdadero. En promedio acierta el
valor del parametro

$$X'X (p \times p)$$

Parte 2.

1- RLS $Y_i = \beta_0 + \beta_1 X_i + \epsilon_i$

RLM $Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \dots + \beta_p X_{pi} + \epsilon_i$

Supuestos

$$E[\epsilon] = 0$$

- errores independientes entre si.

$$\text{Var}(\epsilon) = \sigma^2$$

$$\text{Cov}(\epsilon_i, \epsilon_j) = 0 \quad \forall i \neq j$$

Ambos explican la relación

se estiman sus parámetros

comparten supuestos.

La RLM es una generalización de RLS

Supuesto RLM

$$\bar{Y} = X \bar{\beta} + \bar{\epsilon}$$

$$E(\epsilon) = 0$$


$$\text{Var}(\epsilon) = \sigma^2 I$$

- errores independientes

No multicolinealidad

entre Y y X'

2 -



el error

$$\sum_i \epsilon_i^2 = \sum_i (Y_i - \hat{Y})^2 \quad \begin{matrix} \text{estimada} \\ \hat{Y} = \beta_0 + \beta_1 x_i \end{matrix}$$

$$\Rightarrow \sum_i (Y_i - (\beta_0 + \beta_1 x_i))^2 = F(\beta_0, \beta_1)$$

~~-2~~ -1 función de pérdida

$$\begin{aligned} \textcircled{1} \quad \frac{\partial F}{\partial \beta_0} &= -2 \sum_i (Y_i - \beta_0 - \beta_1 x_i) = -2 \sum_i (Y_i - \beta_0 - \beta_1 x_i) \\ &= -2 \sum_i Y_i + 2n\beta_0 + 2\beta_1 \sum_i x_i \end{aligned}$$

$$\begin{aligned} \textcircled{2} \quad \frac{\partial F}{\partial \beta_1} &= -2 \sum_i (Y_i - (\beta_0 + \beta_1 x_i)) x_i \\ &= -2 \sum_i x_i Y_i + 2\beta_0 \sum_i x_i + 2\beta_1 \sum_i x_i^2 \end{aligned}$$

$$\begin{aligned} \bullet \textcircled{1} \quad \frac{1}{n} \sum x_i &\Rightarrow -\frac{2}{n} \sum Y_i \sum x_i + 2\beta_0 \sum x_i \\ &\quad + \frac{2}{n} \beta_1 (\sum x_i)^2 = 0 \end{aligned}$$

$$\bullet \textcircled{2} - \textcircled{1} :$$

$$\begin{aligned} -2 \sum x_i Y_i + 2\beta_0 \sum x_i + 2\beta_1 \sum x_i^2 + \frac{2}{n} \sum Y_i \sum x_i - 2\beta_0 \sum x_i \\ - \frac{2}{n} \beta_1 (\sum x_i)^2 = 0 \end{aligned}$$

$$B_1 \left[\sum x_i^2 - \frac{1}{n} \frac{n}{n} (\sum x_i)^2 \right] = \sum x_i y_i - \frac{n}{n^2} \sum x_i \sum y_i$$

$$B_1 \left[\sum x_i^2 - n \bar{x}^2 \right] = \sum x_i y_i - n \bar{x} \bar{y}$$

$$B_1 = \frac{\sum_i x_i y_i - n \bar{x} \bar{y}}{\sum_i x_i^2 - n \bar{x}^2} = \frac{\sum_i (x_i - \bar{x}) y_i}{\sum_i (x_i - \bar{x})^2}$$

muestra que $\hat{\beta}_1$ mide la covarianza entre X y Y dividida por la varianza de X

$$\hat{\beta}_1 = \frac{\text{Cov}(X, Y)}{\text{Var}(X)}$$

$$3- \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \Rightarrow \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

$$4- \text{Varianza } \hat{\beta}_1, \hat{\beta}_1 = \sum c_i y_i$$

$$V(\hat{\beta}_1) = V\left(\sum c_i y_i\right)$$

$$c_i = \frac{x_i - \bar{x}}{\sum (x_i - \bar{x})^2}$$

$$V\left(\sum c_i y_i\right) = \sum c_i^2 V(y_i) +$$

$$\sum_{i,j} c_i c_j \text{Cov}(y_i, y_j)$$

$$= \sum c_i^2 V(y_i) = \sum c_i^2 \sigma^2 = \sigma^2 \sum c_i^2$$

$$= \frac{1}{\sum (x_i - \bar{x})^2}$$

$$= \sigma^2 \sum_i \left[\frac{1}{x_i - \bar{x}} \right]^2 = \frac{\sigma^2}{\sum_i (x_i - \bar{x})^2} = \frac{\sigma^2}{S_{XX}}$$

5 -

$$V(\hat{\beta}_0) = V(\bar{y} - \hat{\beta}_1 \bar{x})$$

$$= V(\bar{y}) + \bar{x}^2 V(\hat{\beta}_1) - 2\bar{x} \text{Cov}(\bar{y}, \hat{\beta}_1)$$

$$= V(\bar{y}) + \bar{x}^2 \frac{\sigma^2}{S_{XX}}$$

$$= \frac{\sigma^2}{n} + \bar{x}^2 \frac{\sigma^2}{S_{XX}}$$

6 - el estimador no debería ser dependiente de 1 modelo. se construye con varias observaciones de y para x_0 o con conocimiento a priori de σ^2

Cuando NO, σ^2 se obtiene de los residuos o suma de los cuadrados del error

$$SSE = \sum e_i^2 = \sum (y_i - \hat{y}_i)^2$$

Se propone como estimador σ^2

$$\hat{\sigma}^2 = \frac{SSE}{n-2} \rightarrow \text{grados de libertad}$$

Su distribución dada

$$\sum_i \left[\frac{\hat{y}_i - E(\hat{y}_i)}{\sqrt{\hat{\sigma}^2}} \right]^2 = \sum_i \left[\frac{\hat{y}_i - y_i}{\sqrt{\hat{\sigma}^2}} \right]^2$$

$$= \frac{(n-2) SSE}{(n-2) \hat{\sigma}^2} = \frac{(n-2)}{\hat{\sigma}^2} \hat{\sigma}^2 \sim \chi^2_{(n-2)}$$

La suma de los cuadrados de variables normales independientes sigue una distribución χ^2

Esto sirve para construir los intervalos de confianza.

7- No sesgo para $\hat{\beta}_0$ y $\hat{\beta}_1$

nos
interesa
para
construir
el modelo
ajustado.

$$\bar{y} = \beta_0 + \beta_1 \bar{x} + \bar{e} ; \bar{y} = \hat{\beta}_0 + \hat{\beta}_1 \bar{x}$$

$$- E(\hat{\beta}_0) = E(\bar{y}) - \bar{x} E(\hat{\beta}_1) + E(\bar{e})$$

$$= \beta_0 + \beta_1 \bar{x} + 0 - \bar{x} \beta_1 = \beta_0$$

$$- E(\hat{\beta}_1) = E\left(\sum c_i y_i\right)$$

$$= \sum c_i E(y_i)$$

$$= \sum c_i E(\beta_0 + \beta_1 x_i)$$

$$= \sum c_i (\beta_0 + \beta_1 x_i) = \sum c_i \beta_0 + \sum c_i x_i \beta_1$$

$$= 0 + \beta_1 = \beta_1$$

8- Intervalos de confianza - método pivotal

la cantidad pivotal para β_1

$$t_{\beta} = \frac{\hat{\beta} - \beta_0}{SE(\hat{\beta})}$$

$$T = \frac{\hat{\beta}_1 - \beta_1}{SE(\hat{\beta}_1)}$$

$$T = \frac{\hat{\beta}_1 - \beta_1}{\sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}} \sim N(0,1) \quad \text{no conocemos } \sigma$$

$$T = \frac{\hat{\beta}_1 - \beta_1}{\sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}} \sim t_{n-2} \quad y$$

$$T = \frac{\hat{\beta}_0 - \beta_0}{SE(\hat{\beta}_0)} = \frac{\hat{\beta}_0 - \beta_0}{\sqrt{\hat{\sigma}^2 \left[\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]}} \sim t_{n-2}$$

Intervalo de confianza para β_1

$$\beta_1 \in \left(\hat{\beta}_1 \pm t_{1-\frac{\alpha}{2}, n-2} \cdot \sqrt{\frac{\hat{\sigma}^2}{S_{xx}}} \right)$$

$$\beta_0 \in \left(\hat{\beta}_0 \pm t_{1-\frac{\alpha}{2}, n-2} \cdot \sqrt{\frac{\hat{\sigma}^2}{S_{xx}}} \right)$$

Pruebas de hipótesis

$$H_0: \beta_i = \beta_i^*$$

$$H_a: \begin{cases} \beta_i \neq \beta_i^* \\ \beta_i > \beta_i^* \\ \beta_i < \beta_i^* \end{cases} \quad i=0,1$$

fix

q- RLM

Modelo

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \dots + \beta_K X_{iK} + \varepsilon_i \quad i = 1, 2, \dots, n.$$

En matricial

$$\underline{Y} = \underline{X} \underline{\beta} + \underline{\varepsilon}$$

$$\underline{Y}_{(n \times 1)} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix}; \quad \underline{X}_{n \times p} = \begin{pmatrix} 1 & X_{11} & X_{12} & \dots & X_{1K} \\ 1 & X_{21} & X_{22} & \dots & X_{2K} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & X_{n1} & X_{n2} & \dots & X_{nK} \end{pmatrix}$$

$p = K+1$

$$\underline{\beta}_{p \times 1} = \begin{pmatrix} \beta_0 \\ \vdots \\ \beta_K \end{pmatrix}; \quad \underline{\varepsilon}_{n \times 1} = \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

Estructura del error

$$E(\underline{\varepsilon}) = \underline{0}; \quad V(\underline{\varepsilon}) = \sigma^2 \underline{I}_{n \times n}$$

Propiedades

$$V(X) = \begin{bmatrix} V(X_1) & \dots & \text{Cov}(X_1, X_p) \\ \text{Cov}(X_2, X_1) & & \vdots \\ \text{Cov}(X_p, X_1) & & V(X_p) \end{bmatrix}$$

$$E[X] = \begin{bmatrix} E[X_1] \\ \vdots \\ E[X_p] \end{bmatrix}$$

10 - Supuestos Gauss-Markov

$$\text{supon que } \underline{Y} = \underline{X} \underline{\beta} + \underline{\varepsilon}$$

$$\text{con } E(\underline{\varepsilon}) = 0$$

$$V(\underline{\varepsilon}) = \sigma^2 \underline{I}$$

el estimador de mínimos cuadrados es el mejor estimador lineal insesgado

$$11 = + \varepsilon_i \sim N(0, \sigma^2)$$

$$+ \underline{Y} \sim N(\underline{X} \underline{\beta}, \sigma^2 \underline{I})$$

$$Y_i \sim N(\underline{X}_i \underline{\beta}, \sigma^2) \quad i = 1, \dots, n$$

$$+ \underline{\hat{\beta}} \sim N_p(\underline{\beta}, \sigma^2 (\underline{X}^T \underline{X})^{-1})$$

con \underline{X}_i el vector de covariables del i -ésimo

$$+ \hat{\beta}_j \sim N(\beta_j, \sigma^2 (c_{jj})) ; j = 0, \dots, p$$

[si el j -ésimo elemento en la diagonal de la matriz $(\underline{X}^T \underline{X})^{-1}$]

12-

$$\beta^T: 1 \times p$$

$$X^T X (p \times p)$$

$$X^T: p \times n$$

$$(X^T X)^{-1}: p \times p$$

$$B = X^+ X = \begin{pmatrix} n & \sum x_i \\ \sum x_i & \sum x_i^2 \end{pmatrix} (X^T X)^{-1} = \frac{1}{n S_{xx}} \begin{pmatrix} \sum x_i^2 - n \bar{x}^2 & n \bar{x} \\ \sum x_i & n \end{pmatrix}$$

$$X^T Y = \begin{pmatrix} n \bar{y} \\ \sum x_i y_i \end{pmatrix}$$

$$B = \frac{1}{n S_{xx}} \begin{pmatrix} \sum x_i^2 - n \bar{x}^2 & n \bar{x} \\ \sum x_i & n \end{pmatrix} \begin{pmatrix} n \bar{y} \\ \sum x_i y_i \end{pmatrix}$$

$$= \frac{1}{n S_{xx}} \begin{pmatrix} \sum x_i y_i - n \bar{x} \bar{y} & n \bar{x} \bar{y} + \sum x_i y_i \\ -n \bar{x} \bar{y} + \sum x_i y_i & \sum x_i y_i \end{pmatrix}$$

$$\beta_1 = \frac{\sum x_i y_i - n \bar{x} \bar{y}}{\sum (x_i - \bar{x})^2}$$

$$\beta_0 = \frac{\sum y_i \sum x_i^2 - \sum x_i \sum x_i y_i}{\sum (x_i - \bar{x})^2} = \bar{y} - \beta_1 \bar{x}$$

$$\hat{y} = \beta_0 + \beta_1 \bar{x} = \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix} = \begin{pmatrix} \sum x_i y_i - n \bar{x} \bar{y} \\ \sum (x_i - \bar{x})^2 \end{pmatrix}$$

$$(14) \hat{y} = X \hat{\beta} = X (X^T X)^{-1} X^T Y$$

$$(15) E[\hat{\beta}] = E[(X^T X)^{-1} X^T Y] =$$

$$E[(X^T X)^{-1} X^T (X \beta + \epsilon)] = E[\beta] +$$

no ses guarda

$$(X^T X)^{-1} X^T E[\epsilon] = E[\beta] = \beta$$

(16) Dem $\text{Var}[\hat{\beta}] = \sigma^2 (X^T X)^{-1}$

$$\begin{aligned} \text{Var}[\hat{\beta}] &= E[(\hat{\beta} - E[\hat{\beta}])(\hat{\beta} - E[\hat{\beta}])^T] \\ &= E[(\hat{\beta} - \beta)(\hat{\beta} - \beta)^T] = E[(X^T X)^{-1} X^T (Y - \beta)] \\ &= E[(X^T X)^{-1} X^T (X\beta + \varepsilon) - \beta] = \sigma^2 (X^T X)^{-1} \end{aligned}$$

(17) Establece para los supuestos de regresión lineal a el estimador de mínimos cuadrados como los mejores estimadores lineales insesgados

(18)

$$\begin{aligned} Y &= X\beta + \varepsilon \quad \varepsilon \sim N(0, \sigma^2 I_{n \times n}) \\ E[Y] &= E[X\beta + \varepsilon] = X\beta + E[\varepsilon] \\ &= X\beta \\ \text{Var}[Y] &= \text{Var}[X\beta + \varepsilon] = \text{Var}[\varepsilon] = \sigma^2 I_{n \times n} \end{aligned}$$

(19) $Y \sim N(X\beta, \sigma^2 I_{n \times n})$

(20) $L(\beta, \sigma^2) = (2\pi\sigma^2)^{-n/2} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \hat{y}_i)^2} = \frac{1}{(2\pi\sigma^2)^{n/2}} e^{-\frac{SSE}{2\sigma^2}}$

(27) el num representa SSR suma de cuadrados explicados
 el denominador SSR suma de cuadrados residuales
 sigue una razón de varianzas (estadístico Fisher)

(28) ANOVA
 el RLM se pueden utilizar los
 coeficientes como medias poblacionales,
 para estimar estadístico que
 representa su igualdad o desigualdad

(29) F_0

$$F = \frac{X^2 v_1 / v_1}{X^2 v_2 / v_2} \sim F_{v_1 / v_2}$$

$$F_0 = \frac{SSR / (p-1)}{SSE / (n-p)} \sim F_{p-1, n-p}$$

(30) Tabla

$$SSR = \sum (y_i - \bar{y})^2 \quad p-1 \quad \frac{SSR}{p-1}$$

$$SSE = \sum (y_i - \hat{y}_i)^2 \quad n-p \quad \frac{SSE}{n-p}$$

$$SST = y^T y - n \bar{y}^2 \quad n-1$$